Szorgalmi nagyházi feladat 2024

A félévközi eredmények alapján megajánlott jegy szerezhető, amely a zárthelyi és a szorgalmi nagyházi feladat osztályzatainak átlaga, amennyiben ez minimum 4-es osztályzatot jelent. Szorgalmi házi feladat pótlására nincs lehetőség. Az idei évben a szorgalmi házi feladat a képosztályozás témaköréhez kapcsolódik. A feladatra 2-3 fős csoportok jelentkezhetnek, a jelentkezési határidő: szeptember 20. A jelentkezési módja:

- email küldése a <u>pappd@tmit.bme.hu</u> címre,
- cc-ben: szucs@tmit.bme.hu + legyenek ott a csapattagok
- az email tartalmazza a választott feladatot (A vagy B), és a csapattagok nevét, neptun kódját

Szorgalmi nagyházi feladat:

Implementáljatok egy mélytanulási osztályozó modellt, és tanítsátok be ezt a modellt a tanuló adathalmaz segítségével! Használjatok keresztvalidációt a modell jósági mutatóinak mérésére! Figyeljetek a paraméteroptimalizálásra. Válasszatok minél jobb modellt, rögzítsétek az eredményt, és írjátok le a megoldás részleteit! Van egy tanuló állomány címkeinformációkkal, és a feladat az osztálycímke előrejelzése a teszt adathalmazon manuális tevékenység nélkül (az emberi szemmel történő segítség csalással egyenértékű). A szorgalmi házi feladat a következő részfeladatokból áll:

- Osztályozó modell felépítése, tanítása
- Félév közepén a részarányos haladás bemutatása szóban
- Teszt halmazra predikciók előállítása és beküldése
- Megoldás leírása (miért ezt a modellt választottátok / építettétek, tervezői döntések rövid indoklása) és a dokumentum és a forráskód beküldése
- Megoldásról kiselőadás tartása

A megoldáshoz bármilyen segédszoftver használható; cél a tesztadatsor célváltozójának minél jobb predikciója és minél több saját kontribúció elérése.

Választható feladatok megfelelő adathalmazokkal:

A) Karakterfelismerés

Az adathalmaz kisméretű fekete-fehér képeket tartalmaz, amelyek karakterazonosítóval vannak ellátva. A feladat az ismeretlen képek karakterének (0-9, a-z, A-Z) felismerése egy mélytanulási osztályozóval manuális tevékenység nélkül (az emberi szemmel történő segítség csalással egyenértékű).

A predikciós fájl alapján az oktató kiszámítja a teszthalmaz jósági mutatóit, amiről értesíti a hallgatókat.

Az adathalmaz (technikailag két részből áll: Train1.zip és Train2.zip) letölthető a következő linkekről:

https://drive.google.com/file/d/1QiUPbykXsAAkjy5aKhftSC6tn8_rKpbZ https://drive.google.com/file/d/1KHKtZpnFpuUsdHYsC0kVYv2TlplHnbZ5 a teszthalmaz pedig:

https://drive.google.com/file/d/1zRMDFHMT_decG1PmqsgncuzLy5I_srSh

A predikciós fájlformátuma (példa fájl):

https://drive.google.com/file/d/1_xlPqLhhtQSo1AmUtqXtrJKMEnOGwMh0

B) Gombafelismerés

Az adathalmaz gombákat ábrázoló képeket tartalmaz, amelyek faj azonosítóval vannak ellátva. A feladat két részből áll, egyrészt az ismeretlen képeken a faj felismerése, valamint annak eldöntése, hogy az adott gomba mérgező vagy sem. Tehát egy többosztályos és egy bináris osztályozás lesz a feladat, mélytanulási osztályozó(k) segítségével manuális tevékenység nélkül (az emberi szemmel történő segítség csalással egyenértékű).

Az adathalmaz letölthető a következő linkről:

https://www.imageclef.org/node/318

A fenti linket érdemes átolvasni, hogy bővebb információkhoz jussunk. A félév során kizárólag az adathalmaz tanító része használható, amelyből tetszőleges 100 darab fajt kell kiválasztani, azon kell a többosztályos és bináris osztályozást is elvégezni. A képeken kívül a megadott metaadatok is felhasználhatók, sőt, a versenyen résztvevők publikált eredményeire is lehet támaszkodni.

Fontos, hogy a megoldással szemben követelmény, hogy egy ingyenes Colab-ban futtatható legyen, tehát a fenti linken is említett hardver limitációt be kell tartani!

A féléves munka során ügyeljünk arra, hogy tanító és (a tanító halmazból külön leválasztott) validációs halmazokban is minden kategória jelen legyen, tehát a verseny által visszamért ismeretlen ("unknown") kategória felismerési pontossága esetünkben nem releváns. A kiértékeléshez macro F1-et használjunk. Kiértékelésnél extra módon - a versenyhez hasonlóan - be lehet építeni a többosztályos osztályozás visszamérésébe a mérgező vs. nem mérgező közötti tévesztés büntetését.

A 7. hét végéig emailben (<u>pappd@tmit.bme.hu</u>) meg kell küldeni a választott 100 darab fajt, ami a félév hátralévő részében már nem változtatható!

Értékelési szempontrendszer (bármely feladat esetén):

A könnyebb (karakterfelismerés) feladat esetén figyelembe vesszük az elért jósági értékeket is. Mindkét feladatnál a hozzáadott érték és az elvégzett munka mennyisége nagyban befolyásolja a szorgalmira adott részjegyet. A dokumentáció és a kiselőadások minősége szintén befolyásoló tényező. Összes szempont figyelembevételével történik a részjegy kialakítása.